

自然语言处理实验报告

基于大语言模型的中文分词性能评估与优化

姓名：张宗杼

学号：2023K8009991013

专业：人工智能

2026 年 1 月 13 日

目录

1	实验概述	3
1.1	实验环境与模型	3
1.2	API 调用示例	3
2	标准语料上的分词性能测试	5
2.1	数据来源与预处理	5
2.2	LLM 分词结果	6
2.3	实验结果与分析	8
3	自采集文本分词能力测试	8
3.1	多源数据构建	8
3.2	LLM 分词结果	9
3.3	实验结果与分析	9
4	分词性能提升实验	10
4.1	优化方法: Few-Shot Prompting	10
4.2	LLM 分词结果	11
4.3	实验结果与分析	11
4.4	Few Shot 提示词改进	12
5	结论	13

1 实验概述

本次实验旨在利用大语言模型（LLM）完成中文分词任务。实验选取了不同参数规模的模型，基于《人民日报》语料及网络爬取的多源语料进行测试，评估其分词性能，并探究模型参数量对性能的影响，最后通过 In-Context Learning (Few-shot) 方法尝试提升模型分词性能。

1.1 实验环境与模型

- API 平台: Gitee AI Serverless API (<https://ai.gitee.com/v1>)
- 测试模型:
 - Qwen3-32B (4 元/百万 token)
 - Qwen3-8B (免费模型)
 - DeepSeek-V3 (8 元/百万 token)

1.2 API 调用示例

以下代码是 aigitee 给的 API 调用模板：

```
1 from openai import OpenAI
2
3 client = OpenAI(
4     base_url="https://ai.gitee.com/v1",
5     api_key="XXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXX",
6     default_headers={"X-Failover-Enabled": "true"},
7 )
8
9 response = client.chat.completions.create(
10     messages=[
11         {
12             "role": "system",
13             "content": "You are a helpful and harmless assistant. You should think step-by-
14 ↪ step."
15         },
16         {
17             "role": "user",
18             "content": "Can you please let us know more details about your "
19         }
20     ],
21     model="Qwen3-8B",
```

```

21     stream=True,
22     max_tokens=1024,
23     temperature=0.7,
24     top_p=0.7,
25     extra_body={
26         "top_k": 50,
27     },
28     frequency_penalty=1.0
29 )
30
31 fullResponse = ""
32 print("Response:")
33 # Print streaming response
34 for chunk in response:
35     if len(chunk.choices) == 0:
36         continue
37     delta = chunk.choices[0].delta
38     # If is thinking content, print it in gray
39     if hasattr(delta, 'reasoning_content') and delta.reasoning_content:
40         fullResponse += delta.reasoning_content
41         print(f"\033[90m{delta.reasoning_content}\033[0m", end="", flush=True)
42     elif delta.content:
43         fullResponse += delta.content
44         print(delta.content, end="", flush=True)

```

为了添加提示词，以及隐藏 API Key 等功能，我将上面的代码进行一些修改：

- 将 API 调用封装在函数中，方便批量处理多行文本，以及改变 API 调用方式，使之读取储存在文本文件中的 API Key。
- 在函数内添加了系统提示词明确要求模型保持多行格式返回分词结果。
- 在主程序中实现了按批次读取输入文件、调用分词函数、写入输出文件的逻辑，避免因单次 token 限制导致的处理失败。

部分代码如下所示：

```

1 system_prompt = (
2     "You are a high-efficiency Chinese Word Segmentation tool.\n"
3     "Task: Segment the provided text into words using spaces.\n"
4     "Strict Constraints:\n"
5     "1. The input contains multiple lines. You must process ALL lines.\n"
6     "2. Output format must strictly match the line count of the input.\n"
7     "3. Do NOT merge lines. Do NOT delete lines.\n"
8     "4. Only output the segmented text. No header, no footer, no markdown.\n"

```

```
9     "5. Use single spaces for segmentation."
10 )
11
12 with open('api.txt', 'r') as f:
13     api_key = f.read().strip()
14 def main():
15     with open(OUTPUT_FILE, 'w', encoding='gbk', errors='ignore') as f:
16         pass
17     if not os.path.exists(INPUT_FILE):
18         return
19     lines = []
20
21     with open(INPUT_FILE, 'r', encoding='gbk') as f:
22         lines = [line.strip() for line in f.readlines() if line.strip()]
23
24     total_lines = len(lines)
25     with open(OUTPUT_FILE, 'a', encoding='gbk', errors='ignore') as f_out:
26         for i in range(0, total_lines, BATCH_SIZE):
27
28             batch = lines[i : i + BATCH_SIZE]
29             segmented_block = process_batch(batch)
30             if segmented_block:
31                 f_out.write(segmented_block + "\n")
32
33     print(" 完成")
34
35     print(f"\n结果已保存至 {OUTPUT_FILE}")
```

2 标准语料上的分词性能测试

2.1 数据来源与预处理

利用北京大学标注的《人民日报》1998 年 1 月分词语料，随机抽取 50 个句子作为测试集。数据预处理包括去除原标注中的词性标记，仅保留分词空格作为 Ground Truth，以及去除空格作为模型输入文本。




图 1: 《人民日报》分词语料示例

2.2 LLM 分词结果

以下为部分输出示例：

2.3 实验结果与分析

表 1 展示了三个模型在标准新闻语料上的表现。

表 1: 各模型在《人民日报》测试集上的分词性能

Model	Precision (%)	Recall (%)	F1-Score (%)
Qwen3-8B	79.00	74.42	76.65
Qwen3-32B	85.52	84.54	85.03
DeepSeek-V3	88.55	86.84	87.69

- **参数量影响:** 从实验结果可以看出, 模型的参数量与其分词性能呈正相关。同类模型下, Qwen3-32B (32 亿参数) 在各项指标上均优于 Qwen3-8B (8 亿参数), 显示出更强的语言理解和分词能力。不同模型之间也是如此, DeepSeek-V3 的参数量为 671B, 也因此在这个任务中它的表现最佳。
- **DeepSeek-V3 的具体分析:** DeepSeek-V3 在本次实验中表现最佳, 取得了 88.55% 的精确率和 87.69% 的 F1 值。除了参数量优势外, DeepSeekMoE 架构也是他性能优越的重要因素, 相比于传统的 MoE, DeepSeek 将专家切分得更细, 细粒度的专家允许模型将不同的语言功能分配给专门的专家模块。这种专业化分工使得模型在面对《人民日报》中严肃且多变的句式时, 能更精准地识别语法边界。

3 自采集文本分词能力测试

3.1 多源数据构建

为了测试模型的泛化能力, 利用 Python 爬虫获取了以下三类文本:

1. **古诗文:** 包含文言文和古汉语表达, 句式较为复杂。
2. **豆瓣评论:** 口语化严重, 且含有较多专业领域, 如电影、图书相关词汇。
3. **百度百科:** 说明文性质, 包含较多专有名词。




图 5: 多源文本示例

3.2 LLM 分词结果

以下为部分输出示例：




图 6: DeepSeek-V3 分词结果示例




图 7: Qwen3-8B 分词结果示例




图 8: Qwen3-32B 分词结果示例

3.3 实验结果与分析

在本次实验中，不同模型的输出差异非常大。正如前文所说，Qwen3-8B 的输出不稳定，在本次实验中，其输出甚至出现了错误分行。按照 prompt 的要求，模型应当保

持输出的行数不变，但其却将部分行合并。此外，DeepSeek-V3 分词结果只将最后两个例子分词正确，其余均未按照要求进行分词，只是将汉字一个一个隔开。因此对于无法给出量化结果的分析，仅给出定性分析。

表 2: Qwen32B 在多源文本测试集上的分词性能

Model	Precision (%)	Recall (%)	F1-Score (%)
Qwen3-32B	91.82	87.76	89.74
DeepSeek-V3	44.17	62.54	51.77

- **参数量影响：**与标准语料测试类似，Qwen3-32B 在多源文本上的表现依然优于 Qwen3-8B，不仅性能提升明显，而且输出格式符合提示词要求，显示出更强的语言理解和分词能力。
- **反常现象分析：**在本次实验中，DeepSeek-V3 的表现不仅不如 Qwen3-32B，而且是异常的大幅下降。经分析，原因可能如下：DeepSeek-V3 在分词时出现理解偏差，未能正确理解分词的颗粒度，所以他按照汉字一个一个隔开。而 Qwen3-32B 模型对中文有着很好的场景优化，其内部对分词指令有着极强的默认先验，即使没有示例也能按照词语切分。但是在最后，由于最后两行变成了极度口语化的网络用语，这种文风突变可能使得 DeepSeek-V3 恢复了按词切分的习惯。

4 分词性能提升实验

4.1 优化方法：Few-Shot Prompting

改进实验，我想验证基于 **Few-shot (In-Context Learning)** 的优化方法。

构造的 Prompt 包含 3 个典型示例，涵盖了人名、日期等处理规范。

```

1 FEW_SHOT_PROMPT = """
2 Below are some examples of standard Chinese Word Segmentation:
3
4 Example 1:
5 Input: 迈向充满希望的新世纪
6 Output: 迈向 充满 希望 的 新 世纪
7
8 Example 2:
9 Input: 中共中央总书记江泽民
10 Output: 中共中央 总书记 江泽民
11
12 Example 3:

```

```
13 Input: 1997年12月31日
14 Output: 1997年 12月 31日
15
16
17 Now, please segment the following lines strictly following the style above.
18 """"
```

4.2 LLM 分词结果

以下为部分输出示例：




图 9: DeepSeek-V3 Few-shot 分词结果示例




图 10: Qwen3-8B Few-shot 分词结果示例




图 11: Qwen3-32B Few-shot 分词结果示例

4.3 实验结果与分析

在引入 Few-shot 提示后，模型的分词性能均有显著提升。但是，Qwen3-8B 仍然存在输出不稳定的问题。DeepSeek-V3 和 Qwen3-32B 则均展现了强劲的分词能力。具体

结果如下：

表 3: 各模型在自采测试集上的 Few-shot 分词性能

Model	Precision (%)	Recall (%)	F1-Score (%)
Qwen3-8B	72.47	70.65	71.55
Qwen3-32B	89.78	85.55	87.61
DeepSeek-V3	94.64	91.15	92.86

具体分析如下：

- **Few-shot 效果显著：**引入 Few-shot 示例后，模型的分词性能均有明显提升。通过提供具体的分词示例，模型能够更好地理解任务要求和分词风格，从而提高了准确率和召回率。
- **DeepSeek-V3 明显优化：**DeepSeek-V3 在 Few-shot 提示下表现尤为出色，达到了 92.86% 的 F1 值。这进一步验证了之前的理解偏差假设，通过示例引导，模型能够纠正其分词策略，更加符合预期的分词标准。
- **Qwen3 的差异：**尽管 Few-shot 提示提升了 Qwen3-8B 的性能，但其结果任不如其他两款模型。除此之外，Qwen3-32B 在 Few-shot 提示下出现性能负提升，从 89.74% 提升到 87.61%。经分析，这可能是因为 Few-shot 示例与测试文本风格差异较大，如在示例中未出现关于古文的分词，导致模型在处理古文时未能正确应用示例中的分词风格。

4.4 Few Shot 提示词改进

在 ew Shot 提示词中，添加了更多关于古文和网络用语的分词示例，以期提升模型在多源文本上的分词性能。改进后的提示词如下：

```

1 FEW_SHOT_PROMPT = """
2 Below are some examples of standard Chinese Word Segmentation:
3
4 Input: 迈向充满希望的新世纪
5 Output: 迈向 充满 希望 的 新 世纪
6
7 Input: 中共中央总书记江泽民
8 Output: 中共中央 总书记 江泽民
9
10 Input: 即使是这般光景，也不可轻言放弃。
11 Output: 即使 是 这般 光景 ， 也 不 可 轻 言 放 弃 。

```

```
12
13
14 Input: 天有六气，降生五味。
15 Output: 天 有 六 气 ， 降 生 五 味
16
17 Now, please segment the following lines strictly following the style above.
18 ""
```

表 4: 调整 Few-shot 后 Qwen3-32B 分词性能

Model	Precision (%)	Recall (%)	F1-Score (%)
Qwen3-32B	90.97	86.14	88.48

经过调整 Few-shot 示例后，Qwen3-32B 在多源文本上的分词性能得到了提升，F1 值从 87.61% 提升至 88.48%。这表明通过如上文的猜想，Few-shot 示例的多样性对模型性能有显著影响。

5 结论

本实验系统评估了大语言模型在中文分词任务上的表现。实验表明，参数量更大的模型具备更好的语言理解能力，且通过 Few-shot 提示工程可以显著纠正模型的分词风格，使其更贴近特定的标注规范。